

Ficha Técnica — Detecção de Fraudes em Transações de Cartão

Integrantes: Gustavo Saul, Joao Vitor Valandro, Manuella Schmidt, Matheus Viegas e Rafaella Santos

O projeto busca identificar transações fraudulentas de cartão de crédito. O principal desafio é o forte desbalanceamento das classes: fraudes representam menos de 0,2% das transações. Nesse cenário, liberar uma fraude gera prejuízo financeiro, enquanto bloquear uma compra legítima prejudica a experiência do cliente.

1. Dados

Foi utilizado o dataset público Credit Card Fraud Detection, disponível no Kaggle. O conjunto original contém 284.807 transações, sendo 492 fraudes (0,172%).

As entradas incluem Time, Amount e as variáveis anonimizadas V1 a V28, obtidas por PCA. O alvo é Class, onde 0 representa transação legítima e 1 representa fraude. Após a remoção de duplicatas, foram utilizadas 283.726 transações, divididas de forma estratificada em 70% treino, 15% validação e 15% teste. Time e Amount foram normalizadas com RobustScaler.

2. Arquitetura escolhida

A solução principal utiliza uma MLP para classificação binária:

Entrada (30 features) → Dense 64 (ReLU) → Dropout 20% → Dense 32 (ReLU) → Dropout 20% → Dense 16 (ReLU) → Dense 1 (Sigmoid)

Foram utilizados Adam, Binary Cross-Entropy e Early Stopping. A versão MLP 2 utiliza ainda `class_weight = {0: 1, 1: 5}`, aumentando a importância dos erros envolvendo fraudes durante o treinamento.

Como comparação, também foram avaliados uma MLP sem ponderação e o modelo HistGradientBoosting.

3. Métrica principal

A PR-AUC foi utilizada como principal métrica de acompanhamento, por ser mais adequada para dados extremamente desbalanceados do que a acurácia.

Para a decisão operacional, também foi considerado o custo dos erros, atribuindo custo 100 para falso negativo (fraude liberada) e 5 para falso positivo (compra legítima bloqueada). O limiar de classificação foi escolhido buscando minimizar esse custo.

4. Resultado obtido

No conjunto de teste, a MLP 2 com Class Weights apresentou:

PR-AUC: 0,778 | Recall: 81,69% | Precisão: 65,17% | Acurácia: 99,90% | Custo estimado: 1.455

5. Principais limitações

O conjunto possui pouquíssimas fraudes, dificultando o aprendizado e tornando as métricas sensíveis a poucos exemplos. Além disso, V1 a V28 foram anonimizadas por PCA, reduzindo a interpretabilidade das decisões do modelo.

A MLP ainda deixa passar parte das fraudes — no teste, o recall de 81,69% significa que aproximadamente 18% das fraudes não foram detectadas. O custo utilizado para falsos positivos e falsos negativos também é uma simplificação e precisaria ser definido com dados reais da instituição financeira.